

INSTITUTO SUPERIOR TÉCNICO
LICENCIATURA EM MATEMÁTICA APLICADA E COMPUTAÇÃO
[Projeto Integrador de 1.º Ciclo]

Regimes de Mercado na Zona Euro
Dinâmicas financeiras, económicas e sociais na avaliação
do MSCI Europe.

Autores
Ana Nunes

n.º 110606

Professores
Maria do Rosário Oliveira
Pedro Ferreira dos Santos

8 de Julho, 2026

Abstract

Os mercados de capitais europeus são um tema de grande importância na atualidade, tanto por investidores que procuram gerir o risco das suas carteiras, como por decisores de política económica que procuram antecipar fases de instabilidade. Com a crescente integração financeira e social da Zona Euro, o desafio que se coloca a ambos é como identificar, de forma atempada e fundamentada, a fase de mercado em que nos encontramos, sem depender de critérios arbitrários ou estáticos. No entanto, a literatura sobre *regime-switching* em finanças tende a privilegiar exclusivamente variáveis financeiras, sendo pouco frequente a integração de indicadores de economia real e de bem-estar social nesta discussão.

Realizámos este projeto com o objetivo de contribuir para uma caracterização mais informada e fundamentada dos regimes de mercado *Bull* e *Bear* e dos fatores que os condicionam. Acreditamos que a identificação destes padrões e da sua relação com covariáveis financeiras, económicas e sociais é essencial para uma leitura mais completa da dinâmica dos mercados de capitais europeus.

Este estudo analisa os retornos mensais logarítmicos do índice MSCI Europe entre 1997 e 2024, integrando covariáveis financeiras, de economia real e sociais da Zona Euro. O intuito deste projeto passa por estimar os regimes subjacentes a esta série, de modo a identificar os fatores que mais contribuem para a transição entre fases de expansão e contração.

A abordagem realizada neste trabalho recorre a um Modelo de Markov Oculto Não Homogéneo (HMM-NH), no qual as probabilidades de transição entre regimes e a média da distribuição de emissão dependem de covariáveis externas. Complementarmente, utilizam-se valores de Shapley para decompor, de forma aditiva e exata, a contribuição individual de cada covariável para as probabilidades de transição estimadas.

Palavras-chave: *Hidden Markov Models* (HMM), Regimes de Mercado, Valores de Shapley, MSCI *Europe*

Conteúdo

1	Introdução	4
1.1	Motivação e Contexto	4
1.2	Estado da Arte	4
1.3	Objetivos e Estrutura do Trabalho	5
2	Composição do Conjunto de Dados	5
2.1	Indicadores Financeiros	5
2.2	Indicadores da Economia Real	6
2.3	Indicadores Estruturais e de Bem-Estar Social	6
3	Análise exploratória	7
3.1	Estrutura da Zona Euro	8
3.2	Dinâmica dos Retornos Mensais	9
3.3	Dinâmica da Inflação e da Curva de Juros	10
3.4	Volatilidade	11
3.5	PIB e RNB	12
3.6	Dinâmica da Taxa de Desemprego e do Índice de Confiança do Consumidor	13
3.7	Índice de Gini	15
3.8	Indicador de Criminalidade Violenta e Índice de Corrupção Política	16
3.9	Impacto Ambiental	18
4	Hidden Markov Model (Modelo de Markov Oculto)	19
4.1	Estrutura temporal	19
4.2	Definição formal	20
4.3	Parametrização e Covariáveis	20
4.3.1	Probabilidades iniciais (π)	20
4.3.2	Transições dependentes do tempo (A_t)	21
4.3.3	Probabilidades de emissão (B_t)	21
5	Algoritmos de Inferência e Decodificação de HMM	21
5.1	Estimação de Parâmetros (Algoritmo de Baum-Welch)	21
5.1.1	Quantidades Fundamentais do Algoritmo Forward-Backward	22
5.1.2	O Papel do Newton-Raphson na Atualização da Transição	23
5.1.3	Atualização em Forma Fechada de π e da Emissão	23
5.2	Decodificação Global: O Algoritmo de Viterbi	23
5.2.1	Fase de Avanço	24
5.2.2	Fase de Retrocesso	24
6	Valores de Shapley	24
6.1	Fundamentos da Teoria dos Jogos Cooperativos	24
6.2	Adaptação a Modelos Estatísticos e de Aprendizagem Automática	25
7	Aplicação e Resultados	25
7.1	Construção do HMM	25

7.1.1	Classificação Inicial dos Regimes	26
7.1.2	Impacto da Complexidade Paramétrica: o Modelo Completo	26
7.2	Seleção das combinações de covariáveis testadas	27
7.3	Especificações testadas e critérios de seleção	29
7.4	Análise dos regimes identificados	30
8	Conclusão	31
8.1	Síntese dos Resultados	31
8.2	Comparação com Meligkotsidou e Dellaportas (2011)	31
8.3	Trabalho Futuro	32

1 Introdução

1.1 Motivação e Contexto

Os mercados de capitais europeus alternam entre períodos de crescimento sustentado (*Bull Market*) e períodos de queda acentuada e incerteza elevada (*Bear Market*). Identificar em que regime um mercado se encontra é relevante tanto para a gestão de risco por parte de investidores como para a antecipação de fases de instabilidade por parte de decisores de política económica.

O regime de mercado não é diretamente observável, apenas inferido a partir do comportamento dos preços e de outras variáveis relacionadas, o que torna os *Hidden Markov Models* (HMM) particularmente adequados ao problema. Assumindo ainda que a probabilidade de transição entre regimes varia ao longo do tempo em função de condições financeiras, económicas e institucionais, este trabalho propõe um Modelo de Markov Oculto Não Homogéneo (HMM-NH), no qual as probabilidades de transição e a média da distribuição de emissão dependem de covariáveis externas.

1.2 Estado da Arte

Para a datação de fases de mercado, Pagan e Sossounov [24] estabeleceram uma referência metodológica baseada na identificação de máximos e mínimos locais na série de preços, aplicando limiares de duração e amplitude para classificar os períodos como *Bull* ou *Bear*. Apesar da sua simplicidade e transparência, este método apresenta duas limitações centrais: os limiares utilizados resultam de escolhas arbitrárias do investigador e a classificação obtida é estática, não contemplando persistência de estado nem a incorporação de variáveis explicativas adicionais.

Face a estas limitações, os Modelos de Markov Ocultos surgem como alternativa estatisticamente mais robusta, ao tratarem o regime de mercado como uma variável latente subjacente ao processo observado. Rabiner [20] consolidou os algoritmos fundamentais que sustentam esta abordagem (*Forward-Backward*, *Viterbi* e *Baum-Welch*), enquanto Zucchini e MacDonald [21] alargaram esta formulação a séries temporais com distribuições de emissão contínuas e dependentes de covariáveis, dando origem aos designados modelos não-homogéneos. Nesta linha, Meligkotsidou e Dellaportas [25] aplicaram o conceito à previsão financeira, modelando a média da distribuição de emissão como função linear de covariáveis exógenas, estrutura que é adotada no presente trabalho.

Note-se, ainda, que a literatura sobre *regime-switching* em finanças tende a privilegiar variáveis estritamente financeiras (retornos, volatilidade, estrutura temporal das taxas de juro), sendo menos frequente a integração de indicadores de economia real e de bem-estar social. A relação bidirecional entre desenvolvimento financeiro e desigualdade, evidenciada por Kappel [16], justifica a inclusão de variáveis sociais no presente estudo. Contudo, o alargamento do conjunto de covariáveis introduz problemas de multicolinearidade..

1.3 Objetivos e Estrutura do Trabalho

Este trabalho tem como objetivo estimar e interpretar um HMM-NH de dois estados (*Bull* e *Bear*) para os retornos mensais logarítmicos do índice MSCI Europe, integrando covariáveis financeiras, de economia real e sociais da Zona Euro. Especificamente, pretende-se: (i) caracterizar a dinâmica dos retornos e das covariáveis, (ii) estimar o modelo com o conjunto completo de covariáveis e avaliar os riscos da sua dimensionalidade, (iii) usar valores de Shapley para identificar e analisar as covariáveis mais relevantes e (iv) validar economicamente os regimes identificados.

O restante do trabalho organiza-se da seguinte forma: a Secção 2 descreve o conjunto de dados; a Secção 3 apresenta a análise exploratória; a Secção 4 formaliza o HMM não-homogêneo; a Secção 5 detalha os algoritmos de inferência; a Secção 6 introduz os valores de Shapley; e a Secção 7 apresenta a aplicação empírica e os resultados.

2 Composição do Conjunto de Dados

O presente estudo baseia-se na análise de dados sequenciais, integrando fatores de desempenho dos mercados financeiros com variáveis financeiras, económicas e sociais da Zona Euro. A variável central sob observação é o índice MSCI Europe, utilizado para mapear e identificar os dois regimes clássicos dos mercados de capitais: o estado de expansão (*Bull Market*) e o estado de contração ou crise (*Bear Market*).

A escolha deste indicador justifica-se pelo facto de o MSCI Europe não representar apenas um país ou setor isolado, cobrindo aproximadamente 85% do mercado acionista europeu. Este índice acompanha o desempenho de centenas de empresas de grande e média capitalização distribuídas por 15 países desenvolvidos da Europa. Devido à sua natureza abrangente, as suas flutuações refletem de forma consistente a saúde económica global do continente europeu.

Para identificar os fatores que desencadeiam ou caracterizam os diferentes regimes do MSCI Europe, cruzaremos o desempenho do índice com um conjunto de variáveis estruturais, todas elas partilhando a mesma escala geográfica e económica da Zona Euro.

2.1 Indicadores Financeiros

Seguindo a especificação metodológica proposta por Meligkotsidou e Dellaportas [25] para previsão de séries temporais financeiras através de modelos ocultos de Markov, o primeiro conjunto de covariáveis visa capturar as expectativas dos investidores e a dinâmica interna do mercado acionista:

- **Retornos Passados($t - 1$):** Incluídos para capturar efeitos de *momentum* e modelar a dependência temporal de curto prazo do índice MSCI Europe.
- **Inversão da Curva de Juros:** Calculado como a diferença entre a taxa de juro soberana a 10 anos e a taxa a 3 meses. Uma curva de rendimentos invertida é amplamente reconhecida como um sinal de recessão iminente.

- **Taxa de Juro de Curto Prazo:** Representada pela taxa de juro a 3 meses, refletindo o custo imediato do dinheiro e a orientação da política monetária do Banco Central Europeu.
- **Volatilidade Realizada Passada:** Definida como o desvio padrão dos retornos no período anterior, funcionando como proxy do nível de incerteza e aversão ao risco nos mercados.
- **Inflação:** Reflete a evolução do custo de vida e a estabilidade de preços na zona euro. Uma inflação acima do esperado sinaliza potenciais subidas das taxas de juro por parte do Banco Central Europeu, o que tende a encarecer o crédito, reduzir as margens das empresas e penalizar as avaliações das ações.

2.2 Indicadores da Economia Real

Com o objetivo de analisar a interação entre o desempenho dos mercados financeiros e a condição económica das famílias, foram incorporados indicadores macroeconómicos relevantes:

- **Produto Interno Bruto (PIB):** Mede o valor de mercado de todos os bens e serviços finais produzidos num determinado período. O crescimento do PIB indica uma economia forte e maior consumo, impulsionando as receitas corporativas e promovendo valorização generalizada nos índices bolsistas.
- **Rendimento Nacional Bruto (RNB):** Calculado como o PIB ajustado pelos rendimentos líquidos recebidos do exterior, capturando a riqueza efetivamente disponível dos residentes. Reflete o poder de compra de longo prazo e a capacidade de poupança, funcionando como um indicador estrutural dos fluxos de capital doméstico para o mercado acionista.
- **Taxa de Desemprego Harmonizada da Zona Euro:** O desemprego constitui um dos principais canais de transmissão entre a economia real e os mercados financeiros. O seu aumento reduz o consumo e eleva o risco de incumprimento, afetando negativamente os lucros empresariais. Em sentido inverso, crises nos mercados acionistas tendem a agravar o desemprego.
- **Índice de Confiança do Consumidor (CCI):** Mede o grau de otimismo dos consumidores relativamente à sua situação financeira e perspetivas económicas. A sua deterioração conduz ao adiamento do consumo, afetando diretamente as receitas das empresas.

2.3 Indicadores Estruturais e de Bem-Estar Social

Este estudo adota uma abordagem multidimensional ao incluir variáveis associadas à coesão social e estabilidade institucional [16], assumindo uma relação bidirecional entre o desempenho económico e o bem-estar social.

- **Índice de Gini (Desigualdade de Rendimento):** Utilizado para captar desigualdades estruturais na distribuição de rendimento. Níveis elevados de desigualdade tendem

a limitar o crescimento económico e, consequentemente, o desempenho das empresas. Por outro lado, períodos de crise financeira podem acentuar essas desigualdades.

- **Taxa de Criminalidade:** Considerada como uma proxy da degradação institucional e social. O aumento da criminalidade deteriora o ambiente económico, eleva custos operacionais e desencoraja o investimento. Simultaneamente, períodos prolongados de contração económica tendem a agravar as condições socioeconómicas, contribuindo para o aumento da criminalidade.
- **Poluição do Ar:** Utilizada como um indicador de sustentabilidade ambiental e qualidade de vida. Períodos de forte expansão industrial tendem a agravar os níveis de poluição, enquanto fases de contração económica ou crises financeiras podem reduzir temporariamente as emissões devido à diminuição da atividade produtiva. Assim, esta variável capta tanto a intensidade da atividade económica como as suas externalidades ambientais.
- **Corrupção Política:** Considerada uma métrica central da qualidade institucional e estabilidade governativa. A corrupção distorce os mecanismos de mercado, afasta o investimento direto estrangeiro e aumenta a incerteza jurídica, penalizando a confiança dos investidores. Por outro lado, a deterioração das condições económicas e a instabilidade financeira podem fragilizar as instituições, criando um ambiente propício ao aumento das práticas de corrupção, evidenciando uma relação bidirecional.

3 Análise exploratória

A Figura 1 apresenta a evolução histórica do MSCI Europe desde o início de 1997 até ao período recente (2026), baseando-se nos dados extraídos da plataforma *Backtest* da Curvo [1].




Figura 1: Evolução do MSCI ao longo do tempo

Como se pode observar no gráfico, embora o índice registre uma tendência de crescimento sustentado a longo prazo, o seu percurso é marcado por correções severas e períodos de forte volatilidade que assinalam a transição para regimes de *Bear Market*. Estas quebras abruptas coincidem com grandes choques económicos e geopolíticos, tais como o rebentamento da

bolha das empresas tecnológicas (2000), a Crise Financeira Global (2008), a Crise da Dívida Soberana da Zona Euro (2011-2012) e o choque pandêmico (2020).

3.1 Estrutura da Zona Euro

Para contextualizar o objeto de estudo, é fundamental compreender a configuração atual da Zona Euro e o peso relativo de cada país. A distribuição da população (Figura 2) e a distribuição do PIB (Figura 3), baseadas em dados do Eurostat [2, 3], revelam a existência de uma hierarquia clara entre os Estados-Membros.




Figura 2: População da Zona Euro (2024)




Figura 3: PIB da Zona Euro (2024)

Como se observa nas figuras, a Zona Euro não é um bloco homogêneo. Existe um núcleo central formado por potências como a Alemanha e a França, que concentram uma fatia significativa tanto do potencial demográfico como da riqueza produzida na região. Esta centralização indica que o desempenho do mercado europeu e, consequentemente, também do índice MSCI, é fortemente afetado pela estabilidade destas nações.




Figura 4: População da Zona Euro (1997, 2011 e 2024)




Figura 5: PIB da Zona Euro (1997, 2011 e 2024)

O *boxplot* é uma ferramenta estatística que resume a distribuição de dados através de quartis e *outliers*. Os pontos isolados destacam casos que se afastam significativamente da norma. No

contexto da Zona Euro, a análise identifica uma hierarquia clara: Alemanha, França, Itália e Espanha surgem consistentemente como *outliers* superiores tanto no PIB como na população. Para avaliar a dispersão relativa das variáveis, utilizou-se o Coeficiente de Variação (CV), definido pela razão entre o desvio-padrão (σ) e a média (μ):

$$CV = \frac{\sigma}{\mu} \quad (1)$$

Esta métrica permite comparar a variabilidade de conjuntos de dados com unidades distintas, sendo que um valor mais elevado de CV indica uma maior dispersão dos dados em relação à média, refletindo uma maior heterogeneidade estrutural.

A computação do CV revela dinâmicas distintas entre as variáveis demográficas e económicas. Enquanto a distribuição da população entre os Estados-Membros apresenta uma estabilidade notável, com variações residuais no seu coeficiente de dispersão ($\Delta CV_{pop} = -0,0176$), o PIB apresenta uma tendência de redução da sua variabilidade relativa ($\Delta CV_{pib} = -0,198$).

3.2 Dinâmica dos Retornos Mensais

Neste estudo, optou-se pela utilização de retornos logarítmicos, cuja escolha se justifica por propriedades estatísticas cruciais para a modelagem financeira: a aditividade temporal e a aproximação à normalidade. Nesse contexto, a análise da dinâmica dos retornos mensais logarítmicos do índice MSCI Europe foi estruturada para identificar padrões de dependência serial. O cálculo dos retornos seguiu a seguinte fórmula:

$$r_t = \ln \left(\frac{P_t}{P_{t-1}} \right) \quad (2)$$

onde r_t representa o retorno logarítmico no período t , P_t o nível do índice no período t , e P_{t-1} o nível no período imediatamente anterior.

A estacionariedade da série foi validada através do Teste de Dickey-Fuller Aumentado (ADF). O valor da estatística de teste ($\tau_2 = -17,82$) foi significativamente inferior ao valor crítico de 5% ($-2,86$), permitindo rejeitar a hipótese nula de raiz unitária e confirmar que os retornos oscilam em torno de uma média estável.

Uma vez confirmada a estacionariedade da série através do teste ACF, foi possível proceder à análise da sua estrutura de dependência temporal utilizando dois testes complementares. A função de Autocorrelação (ACF) revelou que todos os coeficientes para os 24 *lags* (24 meses) permanecem dentro das bandas de significância, indicando a ausência de memória nos retornos.




Figura 6: Função de Autocorrelação (ACF) dos retornos mensais

3.3 Dinâmica da Inflação e da Curva de Juros

Para compreender a dinâmica macroeconómica, analisou-se a evolução da Taxa de Inflação Anual e o seu impacto no Diferencial da Curva de Juros na Zona Euro entre 1997 e 2024, com base em dados compilados do Banco Central Europeu [4] e da Federal Reserve Bank of St. Louis [5]. A dinâmica do diferencial da curva de juros, frequentemente utilizado como indicador de expectativas económicas, é calculado através da diferença entre as taxas de juro de longo prazo e de curto prazo:

$$\text{Diferencial} = \text{Taxa de longo prazo (10 anos)} - \text{Taxa de curto prazo (3 meses)}$$

A inflação apresentou um mínimo de -0,7% (julho de 2009) e um máximo de 10,6% (outubro de 2022). O diferencial da curva de juros exibiu períodos de inversão críticos (spread < 0), nomeadamente antes da crise financeira de 2008 e no ciclo recente de 2023-2024.

Para isolar a componente cíclica da inflação e do diferencial de juros da sua trajetória de longo prazo, aplicou-se o Filtro de Hodrick-Prescott (HP). Esta decomposição é essencial para remover o "ruído" estatístico e as variações estruturais de longo prazo, permitindo uma análise focada no ciclo económico.



Figura 7: Inflação e a sua Tendência




Figura 8: Curva de Juros e a sua Tendência

Ao subtrair a tendência da série original, obtemos o "desvio cíclico". Esta transformação permite identificar as fases de sobreaquecimento ou arrefecimento económico, garantindo que as correlações observadas reflitam a dinâmica intrínseca dos ciclos e não apenas tendências comuns de longo prazo.




Figura 9: Desvio Cíclico da Inflação




Figura 10: Desvio Cíclico da Curva de Juros

Para validar a relação entre as variáveis, procedeu-se à verificação da estacionariedade através do teste Augmented Dickey-Fuller (ADF). Tanto os componentes cíclicos da inflação quanto os do curva de juros revelaram-se estacionários ($p\text{-value} < 0,01$), conferindo robustez estatística à análise de correlação cruzada (CCF).




Figura 11: Correlação Cruzada (Curva de Juros vs Inflação)

A análise da correlação cruzada revela um padrão de comportamento cíclico significativo com um desfasamento de aproximadamente 7 a 10 meses. Isto sugere que o ciclo do diferencial de juros tende a preceder o ciclo da inflação. Este resultado é fundamental, pois indica que o comportamento da curva de juros contém informação preditiva relevante para a trajetória futura da inflação.

3.4 Volatilidade

Nesta secção, analisamos a volatilidade mensal, um fator crucial para a compreensão do risco de mercado e da instabilidade económica. A volatilidade é aqui calculada através do desvio-

padrão dos retornos logarítmicos definidos como $r_t = \ln(P_t/P_{t-1})$, sendo P_t o preço do ativo no período t . O cálculo processa-se numa janela deslizante de $n = 12$ meses, decisão validada por: Fama (1965) [6].




Figura 12: Evolução da Volatilidade ao longo do tempo

a evidência empírica é robusta ao demonstrar que a inflação e a curva de juros na Zona Euro não são variáveis isoladas. Elas compõem um sistema dinâmico de interdependência, onde o mercado financeiro antecipa a inflação, por aproximadamente de 7 a 9 meses, mas é também por ela condicionada através da política monetária uma vez que no lado positivo se vê uma influência relevante

3.5 PIB e RNB

Para consolidar a nossa análise, examinámos a trajetória do Produto Interno Bruto (PIB) e do Rendimento Nacional Bruto (RNB) na Irlanda, em Portugal e na Zona Euro. Com base nos dados do *Eurostat* [3,7] e utilizando o ano de 2010 como referência (2010 = 100), percebemos dinâmicas distintas. Enquanto em Portugal e na Zona Euro as trajetórias do PIB e do RNB demonstram uma convergência histórica com o RNB ligeiramente abaixo do PIB, na Irlanda observa-se que o PIB apresenta um crescimento muito superior ao do RNB, fenómeno frequentemente associado à distorção causada pela atividade de empresas multinacionais no território irlandês.




Figura 13: PIB vs RNB da Zona Euro




Figura 14: PIB vs RNB de Portugal e da Irlanda

Do ponto de vista comparativo, verifica-se que o PIB da Irlanda ultrapassou o de Portugal em 2005, enquanto a convergência entre o RNB irlandês e o português ocorreu apenas mais recentemente, no segundo trimestre de 2020. Para quantificar a relação entre estas variáveis na Zona Euro, foi aplicado um modelo de regressão linear simples com correção de erros robustos (HAC) aos ciclos do PIB e RNB encontrados a partir do Filtro de Hodrick-Prescott (HP) para garantir a estacionariedade. Foi obtido um coeficiente de determinação (R^2) de 96,52%. Este resultado indica que, a nível agregado da Zona Euro, o RNB explica quase a totalidade da variação do PIB, confirmando uma associação estrutural extremamente elevada entre os dois agregados macroeconómicos.

Dada esta forte associação estrutural, e uma vez que o RNB está disponível com periodicidade mensal, optou-se por utilizar exclusivamente o RNB como proxy da atividade económica real na análise HMM-NH.

3.6 Dinâmica da Taxa de Desemprego e do Índice de Confiança do Consumidor

Para compreender a dinâmica cíclica da economia real, analisámos a evolução da Taxa de Desemprego e do Índice de Confiança do Consumidor (ICC) na Zona Euro entre 1997 e 2024. A análise fundamenta-se em dados quantitativos extraídos da plataforma *OECD Data Explorer* [8,9], que fornece a taxa de desemprego mensal harmonizada e ajustada sazonalmente e o ICC que compila inquéritos de opinião sobre a situação financeira e as perspetivas futuras das famílias. Este oscila em torno de um valor neutro de zero, onde os valores positivos indicam um cenário de otimismo, enquanto valores negativos sinalizam um contexto de pessimismo ou cautela.

A análise histórica das séries em níveis (Figuras 15 e 16) revela trajetórias com volatilidade marcada, evidenciando o impacto de crises económicas. Aplicou-se o Filtro de Hodrick-Prescott (HP), para isolar a componente cíclica permitindo uma análise focada na dinâmica intrínseca dos ciclos económicos.




Figura 15: Taxa de Desemprego e a sua Tendência




Figura 16: ICC e a sua Tendência

Ao subtrair a tendência da série original, obtemos o desvio cíclico. Esta transformação permite identificar as fases de sobreaquecimento ou arrefecimento económico.



Figura 17: Desvio Cíclico da Taxa de Desemprego




Figura 18: Desvio Cíclico do ICC

Para validar a relação entre as variáveis, procedeu-se à verificação da estacionariedade dos ciclos através do teste *Augmented Dickey-Fuller* (ADF). Ambos os componentes cíclicos revelaram-se estacionários ($p\text{-value} < 0,01$), conferindo robustez estatística à análise de correlação cruzada (CCF).




Figura 19: Correlação Cruzada (Ciclo Desemprego vs Ciclo ICC)

A análise da correlação cruzada revela uma relação negativa persistente e significativa entre o desemprego e o ICC. A magnitude das correlações sugere que as alterações na confiança do consumidor tendem a preceder os movimentos no mercado de trabalho. Este resultado é fundamental, reforçando o papel do ICC como um importante indicador antecedente, refletindo como o sentimento das famílias antecipa as mudanças cíclicas no desemprego na Zona Euro.

3.7 Índice de Gini

O Índice de Gini mede a desigualdade na distribuição de rendimentos (0 a 100). Dada a escassez de séries históricas longas e harmonizadas para a Zona Euro, implementámos uma metodologia de ponderação económica, agregando dados das onze principais economias do bloco, conforme consultado em CountryEconomy.com [10]. A agregação obedeceu à seguinte especificação:

$$Gini_{Euro,t} = \frac{\sum_{i=1}^n (Gini_{i,t} \times SharePIB_{i,t})}{\sum_{i=1}^n SharePIB_{i,t}} \quad (3)$$

Instituições de referência, como o Banco Central Europeu [17] e o Fundo Monetário Internacional [18], argumentam que o uso de uma média aritmética simples é insuficiente para agregar fatores de desigualdade, defendendo o uso de ponderações económicas baseadas nas maiores economias. Para validar a fiabilidade deste indicador, cruzámos o Gini Ponderado com o Gini Real oficial da Zona Euro.




Figura 20: GINI ponderado vs GINI da Zona Euro

Para validar a hipótese de que o Índice de Gini ponderado pelo PIB é idêntico ao Índice de Gini real da zona Euro usámos dois métodos simples, uma vez que temos uma quantidade de dados muito reduzida para usarmos o filtro HP como anteriormente. Primeiro, comparámos as variações ano-a-ano das duas séries, o que indicou uma relação forte entre os dois índices ($R^2 = 89,80\%$, altamente significativo ($p < 0,0001$)). Depois, ajustámos uma linha reta à evolução de cada série ao longo dos anos e calculámos, para cada ano, a diferença entre o valor real e o valor previsto pela tendência. Estes desvios ao serem comparados confirmaram os resultados anteriores ($R^2 = 81,37\%$, altamente significativo ($p < 0,0001$)).

3.8 Indicador de Criminalidade Violenta e Índice de Corrupção Política

Para analisarmos a criminalidade violenta, agregámos a Taxa de Homicídios por 100.000 habitantes, ponderando as taxas nacionais pela dimensão populacional, tal como mostra a seguinte fórmula:

$$\bar{H} = \frac{\sum_{i=1}^n (H_i \times P_i)}{\sum_{i=1}^n P_i} \quad (4)$$

Os dados utilizados para este cálculo foram obtidos através do *Intentional Homicide: Data Portal* [11].




Figura 21: Evolução da Taxa de Homicídios

O indicador iniciou o período no seu máximo histórico em 1997 (1,91), registando um ciclo de pacificação social até ao mínimo em 2021 (0,83), com uma reversão recente no período pós-2022. Além de possíveis fatores sociológicos, não é possível descartar o impacto de alterações metodológicas na harmonização de dados criminais, bem como o efeito de regularização de registos pendentes do período pandémico, que podem induzir uma leitura inflacionada da taxa de homicídios no período mais recente.

Para avaliar a dimensão institucional, utilizámos o Índice de Corrupção Política. Este indicador, desenvolvido pelo *V-Dem Institute* e disponibilizado pelo portal *Our World in Data* [12], baseia-se em estimativas de especialistas sobre a extensão em que o poder executivo, legislativo, judiciário e a burocracia se envolvem em práticas de suborno e apropriação indevida de fundos públicos. A agregação para o conjunto da Zona Euro foi realizada através de três metodologias distintas: média aritmética simples, ponderação populacional e ponderação pelo PIB.




Figura 22: Índice de Corrupção Política




Figura 23: CCF (Índice de Criminalidade vs Índice de Corrupção)

A análise gráfica demonstra dois padrões distintos: entre 1997 e 2017, verificou-se uma diminuição consistente no índice da corrupção, contudo, a partir de 2019, iniciou-se uma inflexão ascendente, semelhante com o que vimos do índice de criminalidade violenta. A componente cíclica foi extraída através do filtro *Hodrick-Prescott*, subtraindo a tendência de

longo prazo à série original, o que garante que as correlações reflitam a dinâmica dos ciclos e não tendências comuns. A estacionariedade foi validada pelo teste KPSS, que não rejeitou a hipótese nula de estacionariedade em nenhum dos ciclos, suportando a aplicação da CCF. A CCF revela que a única correlação estatisticamente significativa ocorre no lag 0 ($r = 0,661$), indicando que criminalidade e corrupção co-movem no mesmo ano, sem que nenhuma variável antecipe temporalmente a outra.

Na análise da qualidade institucional e dos seus reflexos na esfera política, selecionámos três países para um estudo comparativo detalhado, França, Itália e Portugal. Utilizando a Finlândia como referencial de resiliência institucional, a Figura ilustra a evolução do Índice de Corrupção Política. Percebemos trajetórias divergentes: enquanto a Finlândia mantém níveis elevados de integridade, Portugal e, sobretudo, a Itália, exibem um agravamento acentuado da corrupção no período pós-2018. Em contraste, a França apresenta uma trajetória distinta, não registrando um aumento significativo nos níveis do Índice de Corrupção ao longo do período analisado. Paralelamente, a Figura 20 detalha o crescimento eleitoral de partidos de extrema-direita nestes três países, baseado em dados da base *ParGov* [14, 15]. Esta revela uma tendência de ascensão que se intensificou a partir de 2018, semelhante ao que aconteceu ao Índice de Corrupção de Portugal e da Itália




Figura 24: Índice de Corrupção Política (Finlândia, Portugal, França e Itália)




Figura 25: Crescimento de Partidos de Extrema-Direita (Portugal, França e Itália)

3.9 Impacto Ambiental

Para analisarmos o impacto ambiental, somámos as emissões totais de todos os países da Zona Euro, utilizando como escala a unidade de toneladas métricas de CO₂, segundo dados disponibilizados pelo *Our World in Data* [13].




Figura 26: Evolução das Emissões de CO₂ ao longo do tempo

A evolução temporal deste indicador revela uma trajetória de descarbonização estrutural, principalmente devido a medidas anti-poluentes implementadas na zona Euro, oscilando entre o seu máximo em 2005 (2.966.647.121 toneladas) e o seu mínimo registado em 2024 (1.873.133.805 toneladas).

4 Hidden Markov Model (Modelo de Markov Oculto)

Os Modelos de Markov Ocultos (Hidden Markov Models – HMM) são amplamente utilizados como ferramentas de modelação e classificação de dados sequenciais. A sua aplicação encontra-se bem documentada na literatura.

Neste trabalho, propõe-se uma extensão do modelo clássico, o Modelo de Markov Oculto Não Homogéneo (HMM-NH), que introduz dependência temporal explícita e integração de covariáveis, permitindo uma modelação mais flexível e realista.

A utilização do Modelo de Markov Oculto com transições não-homogéneas distingue-se da formulação clássica (homogénea) pela introdução de transições dinâmicas entre estados. Enquanto num modelo convencional as probabilidades são estáticas, nesta estrutura elas evoluem à medida que o tempo progride e as condições externas se alteram, permitindo capturar a variabilidade inerente a sistemas de longo prazo, conforme fundamentado por Zucchini e MacDonald [21].

4.1 Estrutura temporal

O funcionamento deste modelo assenta num eixo temporal comum (t), normalizado para o intervalo $[0, 1]$: $t = 0$ corresponde à primeira observação da amostra e $t = 1$ à última, com os instantes intermédios distribuídos proporcionalmente à sua posição na sequência. Esta normalização permite que o efeito de tendência temporal captado pelo modelo seja comparável independentemente da dimensão absoluta da amostra, sem necessidade de recorrer à escala calendária original.

4.2 Definição formal

Um HMM é definido por um conjunto de parâmetros $\lambda_t = (\pi, A_t, B_t)$, onde:

- $S = \{s_1, \dots, s_N\}$: conjunto de estados latentes (neste trabalho, $N = 2$: *Bear* e *Bull*);
- $O_t \in \mathbb{R}$: variável observada em cada instante t (neste caso, o retorno logarítmico mensal do ativo);
- $A_t = [p_{ij}^{(t)}]$: matriz de transição entre estados;
- $B_t = [b_i(o_t)]$: probabilidades de emissão;
- $\pi = [\pi_i]$: distribuição inicial dos estados.

O modelo gera uma sequência de observações

$$O = (o_1, o_2, \dots, o_T)$$

assumindo duas propriedades fundamentais:

- **Propriedade de Markov**: cada estado depende apenas do estado anterior;
- **Independência condicional**: cada observação depende apenas do estado atual.

4.3 Parametrização e Covariáveis

A característica central do HMM-NH é a incorporação de covariáveis externas nos parâmetros do modelo por meio de funções *link* [21]. Embora, na formulação geral, π , A_t e B_t possam depender de covariáveis, neste trabalho essa dependência foi restrita a A_t e à média de B_t . A distribuição inicial π foi mantida como vetor livre, estimado diretamente da ocupação de estados no primeiro instante amostral, já que a amostra tem um único ponto de início fixo.

Na prática, a estimativa de π acaba por ficar muito próxima de 0 ou de 1, ou seja, o modelo "decide" com quase total certeza qual era o estado inicial em janeiro de 1997, em vez de apresentar uma probabilidade mais equilibrada. Isto acontece porque π é calculado a partir de uma única observação. É importante notar que este comportamento afeta apenas π , e não a qualidade do modelo como um todo pois as probabilidades estimadas para os restantes meses da amostra continuam bem distribuídas e informativas, permitindo identificar corretamente os períodos de regime *Bull* e *Bear* ao longo do tempo. O valor extremo de π deve, portanto, ser entendido como uma limitação decorrente de se estimar este parâmetro com base num único ponto de partida.

4.3.1 Probabilidades iniciais (π)

A distribuição inicial resulta diretamente da probabilidade de ocupação de estado no primeiro instante, obtida no Passo E do algoritmo:

$$\pi_i = \gamma_1(i) \tag{5}$$

sem parametrização adicional em função de covariáveis.

4.3.2 Transições dependentes do tempo (A_t)

$$p_{ij}^{(t)} = \frac{\exp(\eta_{ij}^{(t)})}{\sum_{k=1}^N \exp(\eta_{ik}^{(t)})}, \quad \eta_{ij}^{(t)} = \beta_{ij,0} + \beta_{ij,1} t + \sum_m \beta_{ij,m} X_m^{(t)} \quad (6)$$

Para $N = 2$, esta parametrização reduz-se a uma regressão logística:

$$p_{i1}^{(t)} = \frac{1}{1 + \exp(-\eta_{i1}^{(t)})}, \quad p_{i2}^{(t)} = 1 - p_{i1}^{(t)} \quad (7)$$

4.3.3 Probabilidades de emissão (B_t)

Como a variável observada é contínua (o retorno logarítmico mensal), a densidade de emissão adotada é Gaussiana [20,21]. A média $\mu_i^{(t)}$ segue a estrutura linear-Gaussiana proposta em [?], na qual a média da densidade de emissão é especificada como função linear de covariáveis exógenas, com coeficientes específicos de cada estado.

$$b_i(o_t) = \frac{1}{\sigma_i \sqrt{2\pi}} \exp\left(-\frac{(o_t - \mu_i^{(t)})^2}{2\sigma_i^2}\right) \quad (8)$$

$$\mu_i^{(t)} = \phi_{i,0} + \phi_{i,1} t + \sum_m \phi_{i,m} X_m^{(t)} \quad (9)$$

A esta estrutura acrescenta-se, neste trabalho, um termo de tendência temporal linear ($\phi_{i,1} t$), permitindo capturar uma deriva sistemática da média condicional ao longo da amostra, para além do efeito das covariáveis.

5 Algoritmos de Inferência e Descodificação de HMM

Os Modelos de Markov Ocultos (HMM) recorrem a algoritmos fundamentais para estimação de parâmetros e inferência de estados latentes. Destacam-se o algoritmo de Baum-Welch e o algoritmo de Viterbi [20], bem como o método de Newton-Raphson [21], aplicado apenas a uma das componentes do Passo M, como se detalha adiante.

5.1 Estimação de Parâmetros (Algoritmo de Baum-Welch)

Para viabilizar a computação eficiente, Baum introduz duas variáveis calculadas por recursão que permitem determinar a probabilidade de ocupação de cada estado em cada instante de tempo, sem computar caminhos individuais:

Variável Forward ($\alpha_t(i)$) Representa a probabilidade (densidade, no caso de emissão contínua) de observar a sequência parcial até ao tempo t e o sistema encontrar-se no estado s_i :

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) p_{ij}^{(t)} \right] b_j(o_{t+1}) \quad (10)$$

Variável Backward ($\beta_t(i)$) Representa a probabilidade da sequência futura de observações a partir do instante $t + 1$, dado que o sistema está no estado s_i no tempo t :

$$\beta_t(i) = \sum_{j=1}^N p_{ij}^{(t)} b_j(o_{t+1}) \beta_{t+1}(j) \quad (11)$$

Ambas as recursões são implementadas com normalização (*scaling*) a cada instante t , para evitar problemas numéricos de *underflow* decorrentes do produto sucessivo de densidades ao longo de séries longas.

5.1.1 Quantidades Fundamentais do Algoritmo Forward-Backward

Verosimilhança Total da Amostra (P)

$$P(O | \lambda) = \sum_{i=1}^N \alpha_t(i) \beta_t(i) \quad (12)$$

Probabilidade de Ocupação de Estado ($\gamma_t(i)$)

$$\gamma_t(i) = \frac{\alpha_t(i) \beta_t(i)}{P(O | \lambda)} \quad (13)$$

Probabilidade de Transição ($\xi_t(i, j)$)

$$\xi_t(i, j) = \frac{\alpha_t(i) p_{ij}^{(t)} b_j(o_{t+1}) \beta_{t+1}(j)}{P(O | \lambda)} \quad (14)$$

Função Auxiliar Q (Objetivo do EM) O Passo M baseia-se na maximização da função auxiliar $Q(\lambda, \lambda')$. *Baum* demonstrou o Teorema da Convergência, provando que, ao encontrar um novo conjunto de parâmetros λ' tal que $Q(\lambda, \lambda') \geq Q(\lambda, \lambda)$, a verosimilhança total do modelo satisfaz necessariamente $P(\lambda') \geq P(\lambda)$:

$$Q(\lambda, \lambda') = \sum_{t=1}^{T-1} \sum_{i=1}^N \sum_{j=1}^N \xi_t(i, j) \ln p_{ij}^{(t)} + \sum_{t=1}^T \sum_{i=1}^N \gamma_t(i) \ln b_i(o_t) \quad (15)$$

Esta função auxiliar decompõe-se aditivamente em duas parcelas independentes, uma relativa aos parâmetros de transição β , outra relativa aos parâmetros de emissão (ϕ, σ) , pelo que cada uma pode ser maximizada separadamente no passo M.

5.1.2 O Papel do Newton-Raphson na Atualização da Transição

Ao contrário dos restantes parâmetros do modelo, os coeficientes de transição $\beta_{ij,\cdot}$ não admitem solução analítica fechada. Recorre-se por isso ao método de Newton-Raphson para encontrar o ponto crítico da log-verosimilhança ponderada, por linha i do modelo de transição [21]:

$$\beta_{i1,\cdot}^{\text{nov}} = \beta_{i1,\cdot}^{\text{antigo}} - H_i^{-1} g_i \quad (16)$$

com o vetor gradiente e a matriz Hessiana dados por

$$g_i = X^\top r_i, \quad r_i = w_{i1} - w_i^{\text{tot}} p_{i1} \quad (17)$$

$$H_i = -X^\top \text{diag}(v_i) X, \quad v_i = w_i^{\text{tot}} p_{i1} (1 - p_{i1}) \quad (18)$$

onde X é a matriz de covariáveis da transição (incluindo o intercepto e a tendência t), $w_{i1} = \xi(i, 1)$ e $w_i^{\text{tot}} = \sum_j \xi(i, j)$. A atualização é regularizada com um termo de *ridge* ($H_i - \lambda I$, $\lambda = 10^{-4}$) para garantir a invertibilidade da Hessiana, e combinada com uma pesquisa em linha (*step-halving*) que assegura o aumento monótono da log-verosimilhança ponderada a cada iteração.

5.1.3 Atualização em Forma Fechada de π e da Emissão

Diferentemente dos coeficientes de transição, tanto a distribuição inicial como os parâmetros da densidade de emissão admitem solução analítica no Passo M, não sendo necessária qualquer iteração de Newton-Raphson:

$$\pi_i^{\text{nov}} = \gamma_1(i) \quad (19)$$

$$\phi_i^{\text{nov}} = (X^\top W_i X)^{-1} X^\top W_i o, \quad W_i = \text{diag}(\gamma_\cdot(i)) \quad (20)$$

$$(\sigma_i^{\text{nov}})^2 = \frac{\sum_{t=1}^T \gamma_t(i) (o_t - X_t \phi_i^{\text{nov}})^2}{\sum_{t=1}^T \gamma_t(i)} \quad (21)$$

isto é, uma regressão linear Gaussiana ponderada pelas probabilidades de ocupação de estado $\gamma_t(i)$, análoga a uma regressão por mínimos quadrados ponderados clássica.

5.2 Descodificação Global: O Algoritmo de Viterbi

A descodificação num Modelo de Markov Oculto (HMM) consiste em identificar a sequência de estados latentes mais provável que gerou uma série observada de eventos. Conforme sistematizado no tutorial fundamental de Rabiner [20], o Algoritmo de Viterbi é a solução padrão para este problema de otimização, aplicando-se de forma inalterada ao caso de emissão contínua ao interpretar $b_j(o_t)$ como densidade em vez de probabilidade pontual.

O algoritmo opera em duas fases distintas: a Recursão de Avanço e o Retrocesso.

5.2.1 Fase de Avanço

Probabilidade Máxima Acumulada (δ)

$$\delta_t(j) = \max_{1 \leq i \leq N} \left[\delta_{t-1}(i) \cdot p_{ij}^{(t)} \right] \cdot b_j(o_t) \quad (22)$$

Ponteiro de Memória (ψ)

$$\psi_t(j) = \arg \max_{1 \leq i \leq N} \left[\delta_{t-1}(i) \cdot p_{ij}^{(t)} \right] \quad (23)$$

5.2.2 Fase de Retrocesso

Estado Final Ótimo

$$s_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)] \quad (24)$$

Recuperação Recursiva

$$s_t^* = \psi_{t+1}(s_{t+1}^*), \quad t = T-1, T-2, \dots, 1 \quad (25)$$

6 Valores de Shapley

A interpretação dos parâmetros de um HMM não-homogêneo torna-se progressivamente mais difícil à medida que o número de covariáveis aumenta, sobretudo porque as probabilidades de transição resultam de uma função na qual o efeito de cada covariável depende dos valores assumidos pelas restantes. Um efeito marginal calculado por perturbação pontual ignora estas interações e é sensível à ordem em que as covariáveis são "ligadas" ou "desligadas". Para ultrapassar esta limitação, recorre-se ao valor de Shapley, um conceito da teoria dos jogos cooperativos que permite decompor de forma aditiva e exata a contribuição de cada covariável para uma previsão do modelo.

6.1 Fundamentos da Teoria dos Jogos Cooperativos

Um jogo cooperativo é definido pelo par (M, v) , onde $M = \{1, \dots, M\}$ é o conjunto de jogadores e $v : 2^M \rightarrow \mathbb{R}$ é a função característica, que atribui a cada coligação (subconjunto) $S \subseteq M$ o valor total que essa coligação consegue gerar de forma independente, com a convenção $v(\emptyset) = 0$. O problema central da teoria dos jogos cooperativos consiste em repartir de forma justa o valor da grande coligação $v(M)$ pelos M jogadores.

Aqui, utilizamos uma solução única para este problema, definida pela média das contribuições marginais de cada jogador k sobre todas as ordens possíveis de formação da coligação:

$$\phi_k(v) = \sum_{S \subseteq M \setminus \{k\}} \frac{|S|!(M - |S| - 1)!}{M!} [v(S \cup \{k\}) - v(S)] \quad (26)$$

Esta é a única alocação que satisfaz simultaneamente quatro axiomas desejáveis [26]:

- **Eficiência:** a soma das contribuições individuais esgota o valor total da coligação completa, $\sum_{k=1}^M \phi_k(v) = v(M) - v(\emptyset)$;
- **Simetria:** dois jogadores que contribuem de forma idêntica para qualquer coligação recebem o mesmo valor;
- **Jogador nulo:** um jogador que não altera o valor de nenhuma coligação a que se junta recebe contribuição nula;
- **Aditividade:** para dois jogos definidos sobre o mesmo conjunto de jogadores, o valor de Shapley do jogo soma é a soma dos valores de Shapley de cada jogo.

6.2 Adaptação a Modelos Estatísticos e de Aprendizagem Automática

A extensão do valor de Shapley à interpretação de modelos preditivos consiste em tratar as covariáveis de um modelo como os jogadores de um jogo cooperativo e a saída do modelo como o valor a repartir. Esta abordagem tem sido cada vez mais adotada como método de *feature importance* em aprendizagem automática, com desenvolvimentos recentes focados em tornar o cálculo computacionalmente viável para modelos de grande dimensão [26] e tem vindo a ser estendida a contextos estatísticos fora do domínio clássico [27].

Formalmente, dado um modelo f e um vetor de covariáveis $x = (x_1, \dots, x_M)$, define-se a função característica como o valor esperado da saída do modelo condicional a que apenas as covariáveis do subconjunto S assumam o seu valor observado, substituindo-se as restantes pela média:

$$v(S) = f(x_S; x_{\bar{S}} = \text{referência}) \quad (27)$$

O cálculo exato de ϕ_k exige a avaliação de $v(\cdot)$ em todas as 2^{M-1} coligações que excluem o jogador k , tornando-se computacionalmente exigente para M elevado. Contudo, para modelos com um número reduzido de covariáveis (como é o caso das equações de transição do HMM-NH utilizado neste trabalho, com $M \leq 10$), o cálculo exato por enumeração exaustiva permanece computacionalmente tratável.

7 Aplicação e Resultados

7.1 Construção do HMM

Para a identificação dos regimes de mercado *Bear* e *Bull*, foi estimado um Modelo de Markov Oculto Não Homogêneo de dois estados, tendo como variável de resposta os retornos logarítmicos (r_t) do ativo.

7.1.1 Classificação Inicial dos Regimes

A distinção entre os regimes baseou-se na premissa de que o estado *Bear* reflete condições de instabilidade, caracterizando-se por retornos baixos e elevada volatilidade, enquanto o estado *Bull* reflete períodos de expansão, com retornos superiores e menor volatilidade. Esta associação entre regimes de queda e um aumento simultâneo da volatilidade condicional está bem documentada na literatura de *regime-switching* aplicada a mercados financeiros [24].

Para definir a etiqueta inicial de cada observação, adotou-se um critério de filtragem baseado em regras simples, seguindo abordagens utilizadas na literatura [24] para identificar fases de mercado. Em particular, a classificação é feita com base em limiares para o retorno e para a volatilidade. Adaptando esta lógica à frequência mensal, um mês t é classificado como *Bear* sempre que:

$$r_t < -0,01 \quad \text{e} \quad \sigma_t^{\text{mensal}} > 0,04$$

caso contrário, o mês é classificado como *Bull*. Como os próprios Pagan e Sossounov [24] assinalam não existe um limiar "verdadeiro" que separe objetivamente um regime do outro, a escolha de -1% e 4% funciona, portanto, apenas como uma etiqueta de arranque (*warm start*) para o algoritmo de Baum-Welch, e não como uma definição estrutural do modelo. A volatilidade não entra como variável de resposta adicional, mas como uma característica latente usada apenas para inicializar a classificação.

7.1.2 Impacto da Complexidade Paramétrica: o Modelo Completo

Antes de proceder à seleção do conjunto de covariáveis mais vantajoso, importa avaliar o comportamento do modelo quando estimado com a totalidade das variáveis explicativas disponíveis. Esta análise serve um duplo propósito: por um lado, estabelece um ponto de referência relativamente ao qual os modelos reduzidos podem ser comparados e por outro, permite ilustrar de forma concreta os riscos associados a uma especificação excessivamente rica em covariáveis correlacionadas, motivando assim a estratégia de redução adotada nas secções seguintes.




Figura 27: Retornos do MSCI por Estado

A Figura apresenta a sequência de regimes identificada pelo modelo *Completo*, estimado com as dez covariáveis consideradas (taxa de inflação, curva de juros, juros a 3 meses, RNB da Zona Euro, taxa de desemprego, ICC, criminalidade, corrupção, emissões e índice de Gini). O padrão visual resultante é marcadamente instável: observa-se uma alternância muito frequente entre os estados *Bear* e *Bull* ao longo de largos troços da série, contrastando com blocos praticamente contínuos do regime *Bear*. Esta coexistência de dois comportamentos extremos constitui uma assinatura típica de *overfitting*, o modelo ajusta-se excessivamente às particularidades da amostra de treino em vez de captar uma dinâmica de regimes.

Uma hipótese plausível para explicar este comportamento é a elevada multicolinearidade entre as covariáveis incluídas no modelo completo.

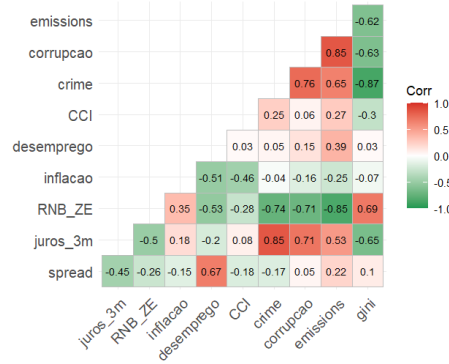


Figura 28: Efeito Marginal das Covariáveis de entrar em Estado *Bear*

Correlações fortes como as observadas entre criminalidade e índice de Gini ($r \approx -0,87$), entre criminalidade e juros a 3 meses ($r \approx 0,85$), entre corrupção e emissões ($r \approx 0,85$) ou entre RNB e corrupção ($r \approx -0,85$) indicam que várias covariáveis transportam, em larga medida, o mesmo sinal macroestrutural subjacente. Em modelos como o presente, a multicolinearidade tende a traduzir-se em coeficientes instáveis e pouco identificáveis. Este excesso de graus de liberdade explicativos, sobrepostos entre si, é consistente com o padrão de ruído observado na sequência de estados e reforça a necessidade da estratégia de redução de covariáveis explorada nas secções seguintes.

7.2 Seleção das combinações de covariáveis testadas

A escolha dos subconjuntos de covariáveis testados baseou-se numa análise prévia dos valores de Shapley, calculados sobre as probabilidades de transição do HMM não-homogéneo estimado com o conjunto completo de covariáveis.




Figura 29: Valores de Shapley por instante t para as probabilidades de transição




Figura 30: Valores de Shapley para a componente de transição, estratificados por nível (alto vs. baixo)

A análise dos valores de *Shapley* permite identificar, de forma quantitativa, a contribuição relativa de cada covariável para as probabilidades de transição do modelo HMM não-homogéneo estimado com o conjunto completo de variáveis.

A **Criminalidade** destaca-se como a variável de maior magnitude de *Shapley* em ambas as direções de transição. As **Emissões de CO₂** surgem em segundo lugar, apresentando também a maior dispersão e a presença de valores atípicos. Os **Juros a 3 meses** revelam um impacto elevado, ainda que concentrado quase exclusivamente na transição *Bear* $\rightarrow$ *Bull*, padrão também observado, embora com menor intensidade, no **Índice de Gini**. A **Corrupção** e o **RNB** apresentam um impacto reduzido mas não negligenciável, enquanto a **Curva de Juros**, o **Desemprego**, o **ICC** e a **Inflação** revelam as magnitudes mais baixas, contribuindo pouco para a capacidade preditiva do modelo.

A estratificação dos valores de *Shapley* por nível da covariável (alto vs. baixo), apresentada na Figura 30, permite ainda interpretar o sentido do efeito de cada variável sobre a transição de regime. Níveis elevados de **Emissões** associam-se à saída do regime *Bear*, um resultado consistente com a hipótese de que maiores emissões refletem maior atividade industrial, típica de períodos de expansão económica. De forma semelhante, níveis baixos dos **Juros a 3 meses** associam-se também à saída do *Bear*, o que é compatível com políticas monetárias acomodáticas implementadas em fases de recuperação económica. Já níveis elevados de **Corrupção** associam-se à entrada em regime *Bear*, resultado que pode ser interpretado à luz da maior instabilidade institucional gerada por níveis de corrupção mais altos.

Nem todos os resultados obtidos através da análise de *Shapley* admitem uma interpretação causal direta. O efeito atribuído à **Criminalidade** é, em particular, pouco intuitivo: o modelo associa níveis elevados de criminalidade à saída do regime *Bear*, quando seria expectável o efeito inverso. Dado que a Criminalidade apresenta forte correlação com a Corrupção e com o RNB pela análise da correlação, é plausível que os valores de *Shapley* estejam a captar, pelo menos parcialmente, efeitos indiretos decorrentes dessa colinearidade, e não um efeito causal direto da criminalidade sobre a dinâmica dos regimes.

De forma análoga, o **Índice de Gini** pode estar sujeito a um efeito espúrio. A variável exhibe

uma tendência lentamente crescente ao longo dos 27 anos de amostra, período que coincide com uma predominância crescente de períodos classificados como *Bull*. É, por isso, possível que o modelo esteja essencialmente a captar duas tendências de longo prazo que evoluem em paralelo sem que isso corresponda a uma relação causal real entre desigualdade e mudança de regime.

Estas ressalvas motivam a definição criteriosa dos subconjuntos de covariáveis a testar, evitando a inclusão de variáveis cujo efeito aparente possa refletir multicolinearidade ou tendências espúrias, em detrimento de um verdadeiro poder explicativo.

7.3 Especificações testadas e critérios de seleção

Com base na análise de Shapley, foram definidas quatro especificações do modelo HMM não-homogêneo:

1. **Modelo 1 – Todas as variáveis:** Curva de Juros, Juros a 3 meses, RNB, Inflação, Desemprego, ICC, Criminalidade, Corrupção, Emissões de CO₂ e Índice de Gini;
2. **Modelo 2 – Base:** Emissões de CO₂, Juros a 3 meses e Corrupção;
3. **Modelo 3 – Alargado:** Emissões de CO₂, Juros a 3 meses, Corrupção, Criminalidade e Índice de Gini;
4. **Modelo 4 – Final:** Emissões de CO₂, Juros a 3 meses, Corrupção, Curva de Juros e ICC.

A seleção entre especificações baseou-se nos critérios de informação de Akaike (AIC) e Bayesiano (BIC), que penalizam a inclusão de parâmetros adicionais, favorecendo modelos parcimoniosos face a modelos sobreajustados. Os resultados obtidos para cada especificação encontram-se resumidos na Tabela 1.

Tabela 1: Comparação das especificações testadas segundo AIC e BIC.

Modelo	k	AIC	BIC
Todas as variáveis	51	-1150,79	-956,12
Base	23	-1169,72	-1081,92
Alargado (+ Crim., Gini)	31	-1163,72	-1045,39
Final (+ Spread, ICC)	31	-1163,67	-1045,34

O **Modelo Base** apresenta simultaneamente o menor AIC e o menor BIC de entre as quatro especificações testadas, com uma diferença especialmente acentuada no BIC face às restantes (-1081,92 vs. valores entre -1045,34 e -956,12), o que reflete o forte peso da penalização por número de parâmetros ($k = 23$, aproximadamente metade dos parâmetros do modelo completo). Este resultado indica que a inclusão das restantes covariáveis, nomeadamente Criminalidade e Índice de Gini, cuja interpretabilidade se mostrou problemática na análise de Shapley, não se traduz em ganhos de ajuste suficientes para compensar o aumento de complexidade do modelo. O Modelo Base foi, por isso, selecionado como especificação de referência para a análise dos regimes.

7.4 Análise dos regimes identificados

A Figura 31 apresenta os retornos mensais logarítmicos do índice MSCI Europe, classificados por regime, para as quatro especificações do modelo testadas e para a classificação por regra fixa (sem estimação de modelo).




Figura 31: Retornos do MSCI por estado nos 4 modelos testados vs na classificação por regra fixa

A comparação visual entre os painéis revela diferenças substanciais na coerência temporal dos regimes identificados. O **Modelo Completo** produz regimes marcadamente fragmentados, com alternâncias frequentes entre estados *Bull* e *Bear* que dificultam a interpretação económica dos períodos identificados como crise. Em contraste, o **Modelo Base** (Modelo 2) identifica regimes *Bear* mais coerentes, concentrados em janelas temporais bem definidas e consistentes com os principais episódios de crise financeira e económica ocorridos no período em análise. A classificação por **regra fixa**, por sua vez, produz uma sequência de estados dispersa e sem persistência temporal, evidenciando a limitação de critérios estáticos (baseados apenas em limiares de retorno e volatilidade) para captar a dinâmica de regimes.

A Figura 32 detalha, de forma isolada, a classificação de regimes obtida pelo Modelo Base ao longo de todo o período amostral (1997–2024).




Figura 32: Retornos do MSCI por estado no modelo 2

Os períodos identificados como *Bear* coincidem com os principais choques conhecidos da Zona Euro, nomeadamente o estouro da bolha tecnológica e a subsequente recessão de 2000 a 2003, a crise financeira global que começou em 2008, a crise da dívida soberana europeia de 2011 a 2012 e o choque associado à pandemia de COVID-19 começando em 2020, o que confirma a validade económica da especificação selecionada e corroborando o resultado obtido através dos critérios AIC e BIC.

8 Conclusão

8.1 Síntese dos Resultados

O presente trabalho estimou um Modelo de Markov Oculto Não Homogêneo de dois estados para os retornos mensais logarítmicos do índice MSCI Europe, integrando covariáveis financeiras, de economia real e de natureza estrutural e social da Zona Euro. Os resultados obtidos permitem retirar um conjunto de conclusões substantivas.

Em primeira análise, o índice MSCI Europe reflete de forma consistente os ciclos económicos da Zona Euro. Tanto na análise exploratória do índice como nos regimes identificados pela especificação selecionada (Modelo Base), encontramos os principais choques conhecidos do período em análise, validando economicamente a nossa abordagem.

Adicionalmente, o HMM não-homogêneo demonstrou capacidade de captar transições dinâmicas entre regimes *Bull* e *Bear*, superando as limitações de abordagens estáticas de classificação. A comparação direta entre a classificação por regra fixa e a classificação obtida pelos modelos estimados evidenciou que a primeira produz uma sequência de estados dispersa e sem persistência temporal, ao contrário dos modelos HMM, em particular o Modelo Base, que identificam regimes *Bear* coerentes e concentrados em janelas temporais bem definidas.

Importa ainda destacar que, a inclusão de covariáveis externas melhorou o modelo, à semelhança do reportado por Meligkotsidou e Dellaportas [25], que demonstraram, para taxas de juro norte-americanas, que um HMM não-homogêneo com seis covariáveis exógenas na matriz de transição supera um HMM homogêneo em termos de capacidade preditiva fora da amostra. Contudo, este trabalho distingue-se do artigo de referência numa dimensão relevante: enquanto Meligkotsidou e Dellaportas se concentram na melhoria da capacidade preditiva agregada do modelo, obtida por *model averaging* sobre um conjunto de especificações candidatas, este trabalho analisa explicitamente o **impacto individual de cada covariável** sobre a dinâmica de transição, através da decomposição de Shapley, uma dimensão que permite uma leitura económica mais detalhada de quais fatores conduzem a mudanças de regime, e em que sentido.

8.2 Comparação com Meligkotsidou e Dellaportas (2011)

É relevante situar as opções metodológicas deste trabalho face às adotadas por Meligkotsidou e Dellaportas [25], dado que a especificação do HMM não-homogêneo aqui utilizada segue de perto a sua formulação geral. Três diferenças metodológicas merecem destaque.

Primeiro, quanto ao **paradigma de inferência**: os autores adotam uma abordagem inteiramente Bayesiana, com estimação via MCMC (*Markov Chain Monte Carlo*) e um algoritmo de *reversible jump* que trata a própria escolha do conjunto de covariáveis como uma quantidade incerta a integrar sobre a posterior. Este trabalho adota, em contraste, uma abordagem frequentista, com estimação por máxima verosimilhança através do algoritmo de Baum-Welch (com o passo M da componente de transição resolvido por Newton-Raphson) e seleção de modelo determinística via AIC/BIC.

Continuando, quanto ao **objetivo declarado do modelo**: o artigo de referência posiciona-se explicitamente como uma ferramenta de previsão (*forecasting*), sendo a qualidade do modelo aferida por uma medida de erro fora da amostra (o *log score* preditivo). Este trabalho, por sua vez, tem um objetivo primariamente explicativo e interpretativo, ou seja, de compreender que fatores explicam a mudança de regime e em que sentido, não tendo sido conduzida uma avaliação formal da capacidade preditiva do modelo fora da amostra.

Terceiro, quanto à **interpretação dos coeficientes**: dado o número reduzido de covariáveis utilizado por Meligkotsidou e Dellaportas (seis, no total), os autores interpretam o efeito de cada covariável diretamente a partir dos coeficientes de regressão logística estimados β_{ij} , mantendo as restantes covariáveis fixas na sua média. Esta abordagem de efeito marginal é razoável quando o número de covariáveis é reduzido e a correlação entre elas é moderada. Neste trabalho, dado o número mais elevado de covariáveis candidatas (dez, no modelo completo) e a correlação elevada observada entre várias delas, optou-se por complementar esta leitura com uma decomposição de Shapley, mais robusta a efeitos de interação e multicolinearidade.

8.3 Trabalho Futuro

Neste contexto, destacam-se três direções prioritárias para investigação futura:

Avaliação explícita da capacidade preditiva. À semelhança da abordagem seguida por Meligkotsidou e Dellaportas [17], seria relevante complementar a análise explicativa aqui desenvolvida com uma avaliação formal da capacidade preditiva do modelo fora da amostra. Esta avaliação permitiria não só validar a utilidade prática do modelo para efeitos de previsão, mas também comparar diretamente o desempenho preditivo das diferentes especificações testadas (Modelos 1 a 4), complementando a comparação baseada em AIC/BIC com um critério orientado à previsão. Numa extensão mais próxima da metodologia do artigo de referência, poderia ainda considerar-se uma abordagem Bayesiana com *model averaging* via *reversible jump* MCMC, permitindo que a incerteza sobre o próprio conjunto de covariáveis seja incorporada nas previsões, em vez de condicionar toda a análise numa única especificação selecionada *a priori*.

Análise de sensibilidade ao estado inicial. Dado que a distribuição inicial π é estimada com base numa única observação, propõe-se uma análise de sensibilidade sistemática dos parâmetros do modelo, em particular dos coeficientes de transição β_{ij} e de emissão ϕ_i face a diferentes pressupostos sobre π , de forma a confirmar a robustez dos resultados substantivos obtidos.

Extensão dos valores de Shapley a interações entre variáveis. A análise de Shapley conduzida neste trabalho considera exclusivamente efeitos isolados de cada covariável. Uma extensão natural consiste em analisar interações de Shapley em pares, o que permitiria testar formalmente a hipótese, aqui apenas sugerida qualitativamente, de que o efeito atribuído à Criminalidade reflete, pelo menos em parte, um efeito indireto via a sua correlação com a Corrupção e o RNB. Esta extensão seria particularmente relevante para distinguir, de forma quantitativa, contribuições genuinamente individuais de contribuições que resultam da estrutura de correlação entre covariáveis.

Referências

- [1] Curvo, *Historical performance of the MSCI Europe index*, Disponível em: <https://curvo.eu/backtest/en/market-index/msci-europe?currency=eur>, Acedido em 18 de Junho de 2026.
- [2] Eurostat, *Population on 1 January by age and sex*, Disponível em: https://ec.europa.eu/eurostat/databrowser/view/demo_pjan, Acedido em 18 de Junho de 2026.
- [3] Eurostat, *Gross domestic product (GDP) and main components (output, expenditure and income) - annual data*, Disponível em: https://ec.europa.eu/eurostat/databrowser/view/nama_10_gdp, Acedido em 18 de Junho de 2026.
- [4] European Central Bank, *HICP Inflation rate - Total - Annual rate of change, Euro area, Monthly*, Disponível em: <https://data.ecb.europa.eu/data/datasets/HICP/HICP.M.U2.N.000000.4D0.ANR>, Acedido em 18 de Junho de 2026.
- [5] Federal Reserve Bank of St. Louis (FRED), *Interest Rates: Long-Term Government Bond Yields and 3-Month Interbank Rates for Euro Area*, Disponível em: <https://fred.stlouisfed.org/series/IRLTLT01EZM156N> e <https://fred.stlouisfed.org/series/IR3TIB01EZM156N>, Acedido em 18 de Junho de 2026.
- [6] Fama, E. F. (1965). *The Behavior of Stock-Market Prices*. The Journal of Business, 38(1), 34-105.
- [7] Eurostat, *Gross value added and income by main industry (NACE Rev.2) - quarterly data*, data extraída conforme apresentado em image_e06f01.jpg, disponível em: https://ec.europa.eu/eurostat/databrowser/view/namq_10_a10_custom_21745336/default/table.
- [8] OECD, *Infra-annual labour statistics*, <https://data-explorer.oecd.org/>, Acedido em 18 de Junho de 2026.
- [9] OECD, *Consumer opinion surveys: Composite consumer confidence*, <https://data-explorer.oecd.org/>, Acedido em 18 de Junho de 2026.
- [10] CountryEconomy.com, *Índice de Gini*, Socio-demografia, consultado em 18 de Junho de 2026. <https://pt.countryeconomy.com/demografia/indice-de-gini>

- [11] United Nations Office on Drugs and Crime (2026). *Intentional Homicide: Data Portal*. Disponível em: <https://data.unodc.org/datareport/hom-victim>, Acedido em 18 de Junho de 2026.
- [12] V-Dem Institute (2025). *Political Corruption Index*. Disponível em: <https://ourworldindata.org/grapher/political-corruption-index>, Acedido em 18 de Junho de 2026.
- [13] Global Carbon Project (2025). *CO2 emissions per capita*. Disponível em: <https://ourworldindata.org/grapher/co-emissions-per-capita>, Acedido em 19 de Junho de 2026.
- [14] ParlGov (2026). *Election data*. Disponível em: https://parlgov.org/data/parlgov-development_csv-utf-8/view_election.csv, Acedido em 23 de Junho de 2026.
- [15] ParlGov (2026). *Party data*. Disponível em: https://parlgov.org/data/parlgov-development_csv-utf-8/view_party.csv, Acedido em 23 de Junho de 2026.
- [16] V. Kappel, *The Effects of Financial Development on Income Inequality and Poverty*, CER-ETH – Center of Economic Research at ETH Zurich, Working Paper 10/127, Março 2010.
- [17] A. F. Amores, H. S. Basso, S. Bischl, P. De Agostini, S. De Poli, E. Dicarlo, M. Flevotomou, M. Freier, S. Maier, E. García-Miralles, M. Pidkuyko, M. Ricci, e S. Riscado, *Inflation, fiscal policy and inequality: The distributional impact of fiscal measures to compensate for consumer inflation*, European Central Bank, Occasional Paper Series, No 330, 2023.
- [18] W. Gbohoui, W. R. Lam, e V. Lledo, *The Great Divide: Regional Inequality and Fiscal Policy*, International Monetary Fund, IMF Working Paper, WP/19/88, 2019.
- [19] Eurostat, *Methodology for assessing the EU Member States’ status and progress towards the SDGs*, European Commission, Unit E.2: Environmental statistics and accounts; sustainable development, 2026.
- [20] L. R. Rabiner, *A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition*, Proceedings of the IEEE, 1989.
- [21] W. Zucchini and I. L. MacDonald, *Hidden Markov Models for Time Series*, Chapman & Hall, 1997.
- [22] A. Churbanov and S. Winters-Hilt, *Implementing EM and Viterbi algorithms for Hidden Markov Model in Python*, BMC Bioinformatics, 2008.
- [23] Hamilton, James D., *A new approach to the economic analysis of nonstationary time series and the business cycle*, Econometrica, Vol. 57, No. 2, pp. 357–384, 1989.
- [24] Pagan, Adrian R. and Sossounov, Kirill A., *A simple framework for analysing bull and bear markets*, Journal of Applied Econometrics, Vol. 18, No. 1, pp. 23–46, 2003.

- [25] Meligkotsidou, Loukia and Dellaportas, Petros, *Forecasting with non-homogeneous hidden Markov models*, Statistics and Computing, Vol. 21, No. 3, pp. 439–449, 2011.
- [26] Zhao, Chi and Liu, Jing and Parilina, Elena, *ShapG: new feature importance method based on the Shapley value*, arXiv preprint arXiv:2407.00506v2, 2025.
- [27] Loureiro, Catarina P. and Oliveira, M. Rosário and Brito, Paula and Oliveira, Lina, *Explainable Outlier Detection for Interval-valued Data*, arXiv preprint arXiv:2606.26307v1, 2026.